

5월 8일 개별 미팅

Week 13 - Hyeok “A benchmark study on time series clustering (2021)”

연구 핵심

- Time series clustering 기법들을 종합적으로 비교한 최초의 대규모 벤치마크 연구
- UCR(UCR Time Series Archive) 내 모든 데이터셋을 활용

연구 동기

- Time Series Clustering에 대한 통합적이고 정확한 벤치마크 연구가 잘 이루어지지 않음
- 기존 연구들은 데이터 셋이 작고, 다양한 방법론과 거리 측정 기준을 동시에 비교한 사례나 비교 기준(성능 측정 방식, 전처리, 클러스터 수 등)이 일관되지 않아 결과 해석이 어려움
- 최대한 공정하고 재현 가능한 평가 프레임워크를 구축해 다양한 시계열 클러스터링 기법을 동일한 조건 하에 비교

Week 13 - Hyeok “A benchmark study on time series clustering (2021)”

Research Question

- 다양한 시계열 클러스터링 기법들 중 어떤 방법이 일관되게 좋은 성능을 보이는가?
- 거리 기준(Euclidean, DTW, Shape-based)과 알고리즘 타입(Partitional, Hierarchical, Density-based)에 따라 성능 차이는 어떻게 되는가?
- 특정 유형의 데이터 셋에 따라 어떤 알고리즘이 적합한가?

Week 13 - Hyeok “A benchmark study on time series clustering (2021)”

기존 연구와 차별점

구분	기존 연구	본 연구
데이터 셋	5~10개 이하	UCR 전체 사용 (128개)
거리 기준	1~2가지 (Euclidean, DTW)	세 가지: Euclidean, DTW, Shape-based
클러스터링 알고리즘	K-means 중심 (classification)	8가지 알고리즘
평가지표	실험마다 다름	- 6가지 제약 조건 동일하게 적용 - 정량적 지표 통일

Week 13 - Hyeok “A benchmark study on time series clustering (2021)”

배경 지식 설명

거리 / 유사도 측정 방식		클러스터링 알고리즘	
Euclidean	- 계산이 빠르고 간단함 - 시계열 간 시간축 변형에 민감 - 고정된 시간축에 정렬된 데이터 값에 적합	Partitional	- K를 정하고 클러스터링 진행. - Centroid 반복적으로 업데이트해서 그룹화. - K-Means, k-shape
DTW	- 두 시계열 포인트들을 비선형적으로 정렬하여 최적의 일치 포인트를 찾음 - 패턴이 비슷하지만 시간축 정렬이 다른 시계열에 사용	Hierarchical	- 데이터를 top-down, bottom-up 방식으로 그룹화 - 유사한 클러스터와 계속 merge - Agglomerative
Shape-based	- 시계열의 모양에 집중함 - 시계열 스케일, offset 차이에 영향을 받지 않음. - 패턴이 유사한 주가 그래프, 심전도	Density-based	- 데이터의 밀도에 따라 클러스터 정의 - 밀도가 낮은 경우 노이즈 처리 - DBSCAN

Week 13 - Hyeok “A benchmark study on time series clustering (2021)”

데이터

- UCR Time Series Archive (2018 기준 128개 데이터셋)
 - 각 데이터 셋은 **labeled time series**로 구성
 - 길이, 클래스 수, 노이즈 유무, 도메인 다양
- 전처리
 - 동일한 길이와 정규화된 상태로 제공 → 추가 전처리 불필요 → **smoothing, scaling** 없음
 - 길이 차이가 있는 경우 DTW나 Shape-based method에서 자동 보정 처리
- 특징
 - 정답 라벨이 포함된 시계열 데이터(최적 K값이 있음)

Week 13 - Hyeok “A benchmark study on time series clustering (2021)”

결론

- 어떤 알고리즘도 모든 데이터에 대해 압도적인 성능을 보이지 않음.
 - 알고리즘 성능은 데이터셋 특성에 따라 달라짐
- 알고리즘을 다양하게 조합해서 사용해야 함.
- 여러 클러스터링 기법을 병렬적으로 사용해서 비교.
- 도메인 마다 도메인에 알맞는 클러스터링 기법 사용 필요.

Week 13 - Hyeok “A benchmark study on time series clustering (2021)”

도메인 특화형 시계열 클러스터링 전략 설계를 통한 지역 경제 패턴 분석 시스템 연구

도메인 특화 클러스터링 조합 기술적 연구

TODO

- 모든 데이터나 도메인에 하나의 클러스터링 기법이 존재하지 않음
- 데이터 특성과 목적에 따라 적합한 클러스터링 전략을 설계하고 조합해야함.
- “도메인 특화된 클러스터링 전략 설계 프레임워크” 디자인

RQ

- 매출 시계열 데이터에 어떤 클러스터링 알고리즘이 가장 적합한가?
- 도메인별로 알고리즘 성능이 어떻게 나오는가?
- 적절한 알고리즘을 선택하거나 조합하는 기준은?
- 시계열 클러스터링과 LLM을 활용해 도시/지역/인구 등 경제 분석이 가능한가?

Week 13 - Hyeok “A benchmark study on time series clustering (2021)”

STEPS

1. 데이터 특성별 최적 클러스터링 설계 및 발견
2. 특화형 시계열 클러스터링 설계를 통한 경제 분석 시스템 개발
3. 시계열 클러스터링 + LLM 기반 해석 자동화

“Designing Domain-Specific Time-Series Clustering Strategies for Local/City Economic Decision Support: An Interpretable System Integrating LLMs”

5월 15일 개별 미팅

Comparing Clustering Algorithms using Financial Time-series data(2019)

연구 목적

- 금융 시계열 길이 차이가 **Clustering**에 미치는 영향
- 동일/불균등 길이 상황별 최적 알고리즘 제시
- 내부지표로 비교

데이터

- 암호화폐 / 2013-2018 / 일별
- SSE 50 주가 / 43종목 / 2008-2018 / 길이 동일 (435일)
- 환율 / 92개 / 2018Q3 / 일별 / 길이 동일
- SET 50 주가 / 50종목 / 2017-18 / 일별 / 길이 동일 (244일)

전처리: 로그 변환 → z-normalization

Comparing Clustering Algorithms using Financial Time-series data(2019)

데이터 특징

- 암호화폐: 상장일이 다름 → **Zone**을 나눠서 길이 분할 / 극단값 **IQR** 적용
- **SSE 50**: 중국 대형주 / 거래정지 종목 제외
- 환율: 3개월 단기 샘플
- **SET 50**: 태국 대형주

결과

데이터셋	최적 K	알고리즘	실루엣스코어
암호화폐	2	Hierarchical + DTW	0.45-0.51
SSE 50	3	Hierarchical	0.41
환율	2	TADPole	0.42
SET 50	2	k-means	0.37

Clustering Huge Number of Financial Time Series (2017, Tomohiro Ando & Jushan Bai)

연구 목적

- 글로벌 금융시장에서 자산 간 이질성이 크고, 단일 모형으로 설명하기 어려움
- 기존 금융 시계열 분석은 고정된 그룹과 낮은 차원에 기반

데이터

- 금융 관련 상장기업 주가수익률
 - 은행, 생명보험, 손해보험, 금융서비스, 부동산
 - 100개 이상 국가, 31개 주요 거래소
 - 약 6,000개 기업
- 2006/7 - 2009/11

전처리: 로그 변환 → z-normalization

Clustering Huge Number of Financial Time Series (2017, Tomohiro Ando & Jushan Bai)

결과

- 기존 금융시장 분석/분류만으로는 훨씬 복잡한 실제 자산 간 수익률 구조를 설명할 수 없음.
- 시계열 수익률은 공통 요인과 그룹별 요인 구조로 설명할 수 있음.
 - 글로벌 위기(금융 위기 등)에선 동일한 반응을 보이고 그룹 수가 증가하는 등
- 고차원 시계열에서 안정적으로 **clustering**할 수 있음.

time series clustering에 초점이 맞춰져 있기 보다는 주가 데이터를 **clustering**할 때 미치는 여러 요인들을 기반으로 **clustering**한 연구

데이터 셋 이상치 검출

평가방법

설명가능하게 만들기

5월 23일

1. 논문 리뷰 Clustering Huge Number of Financial Time Series (2017, Tomohiro Ando & Jushan Bai)
2. 실험 설계

Clustering Huge Number of Financial Time Series (2017, Tomohiro Ando & Jushan Bai)

1. 사용 데이터

- a. 6,000개 이상 글로벌 주식
- b. 2006년 ~ 2009월 (금융위기 전후)

2. 논문 목적

- a. 클러스터링을 위한 논문이 아님
- b. 기존 클러스터링 처럼 수익률이 비슷한 주식끼리 묶는 것이 아니라 같은 요인에 반응하는 주식끼리 묶음
- c. 주식마다 반응하는 요인을 추정하고 요인 반응 패턴이 유사한 주식끼리 그룹화
- d. 각 그룹마다 숨은 요인이 있음
 - i. 금융위기 민감도 / 특정 국가 정책 이슈 등

3. 평가 방법(회기 분석)

- a. 일반 모델과 숨은 요인이 있는 모델을 비교(R^2)
- b. 실제로 숨은 요인을 포함한 모델의 R^2 가 0.57로 설명력 높임

4. 결론

- a. 클러스터링에 목적이 있다기 보단 주식 데이터를 통해 왜 이 주식들이 비슷하게 움직이는지에 대한 설명할 수 있는 구조를 찾고 설명력을 높이기 위한 모델 개발
- b. 클러스터링을 통해 더 잘 설명할 수 있는 회기 모델을 만드는게 목적

매출 특화 클러스터링 기법 실험 설계

1. 소상공인 매출 데이터는 계절성, 급등락, 길이 불균등성 등으로 단일 클러스터링 기법으로는 누락되는 경우가 많음
2. 앙상블 클러스터링 기법 적용
3. **k-shape**과 **DTW**로 계절성/이벤트 패턴 그룹화
4. 업종/위치 등 특징을 바탕으로 노이즈 최소화 및 해석
 - a. 날짜/시간별 (주말, 평일, 출퇴근 시간대, 연말/연초 등) 추가
 - b. 상권

시간에 따른 상권분류 변화도 봐야할 필요가 있음

데이터에 따른 평가 기준 / 군집화 기준을 세워야 한다.

- 시작점과 최고점 까지 시간 / 최저점 까지 시간(있는 경우 없는 경우)
- 최고점에서 최저점까지 기간
- 마지막 날을 기준으로 이전 **10주**까지의 기울기
- 군집화/그룹화 기준을 세우는 요인들에 대해 고민해보기
- **Time series** 에서 요인들을 뽑아낸 경우 찾아보기

5월 29일

1. 방학 계획
2. 연구제안

방학 계획 1

“Domain-specific time-series clustering”

1. 구체적 방법론 구축
2. 데이터 수집
3. 전처리
4. 베이스라인 클러스터링 실행 → k-means, dtw, k-shape
 - a. 기존 클러스터링이 문제다 → 그래서 데이터의 도메인 따라 직접 구분을 하고 classification 모델로 구축
 - b. 클러스터링 결과를 정량적으로 평가할 수 있는 지표/기준 설정
5. 도메인 특화 거리평가 방법/특징 설계
 - a. 데이터 포인트들 간의 거리평가 수식 만들기
6. 커스텀 클러스터링 알고리즘/조합 설정 → 클러스터링 말고 머신러닝 사용
7. 베이스라인 vs 특화모델 비교
8. 글쓰기
9. 구축한 방법론을 다른 데이터에 적용해보기(부동산, 주식 등 가격 데이터) / (저널)
10. 발표자료 작성 및 발표 (상반기)

방학 계획 2

“형상/추세 특성 기반 시계열 클러스터링 해석 및 지표 설계” (제목 미정)

1. 정점/저점 기반 **shape**
2. 최근 모멘텀(**10**주 기간 등)
3. 변동성(평균에서 최대 움직임)
4. 주기/계절성
5. 구조 변화(정책/이벤트 등)
6. 위치(밀집도)

연구 제안 with 정원

“프리미엄 LLM 구독 모델이 초래하는 글로벌 정보·지식 격차”

- 연구 방법에 대한 고민
 - 회사에 가서 N을 크게 잡아서 실험해야함
 - **task**를 하나 확정해야 한다 ⇒ 누가, 어떤 **task**를 할 때의 경우를 보고 싶은가
 - 연구하는 환경에서 **pro** 모델 유무의 차이가 생길 수 있음
 - 사실상 **literature review**할 때 얻는 정보의 차이밖에 없음
 - 실험을 통해서 검증해야 한다
- 예
 - 학부생들을 대상으로 프리미엄 모델 사용 유무를 실험(지식 격차)
 - 실험 방법에 대해 구체적인 고민이 필요하다
 - 실험을 하지 않고 검증할 수 있는 방법이 있을지 고민.. (회사와 함께 하는게 제일 좋을 수도)
 -

6/19 - TiDE 논문 리뷰

TiDE: Time-series Dense Encoder → MLP 기반 Dense Encoder + Temporal Decoder로 긴 구간 시계열을 빠르게 예측하는 모델

Transformer 기반 모델이 긴 구간 예측에서 느린 속도, 높은 메모리 사용 문제. 선형 모델은 빠르지만 비선형, 공변량 처리가 약함

목적: **Attention** 없이도 장기 시계열을 빠르고 정확하게 예측

목표: 다변량 시계열에서 **MSE** 최소화

결과: Weather, Traffic, Electricity, ETT 데이터에서 기존 **SOTA** 대비 평균 **5%** 이상 오차 감소, 추론 속도 **5-10배** 향상

한계점: 금융, high-volatility 데이터 검증 부족

6/19 - TiDE 논문 리뷰

시계열 데이터 예측 모델

기존 Transformer는 계산량이 데이터의 길이로 늘어남

계산 양을 줄인 선형 모델은 빠르지만 복잡한 패턴, 외부 변수(날짜, 날씨) 반영 미흡

TiDE라는 새 모델 제안

- Dense Encoder: 과거 데이터를 압축해 하나의 요약 벡터로 바꿈
- Temporal Decoder: 앞으로 일어날 날짜, 요일 정보와 요약 벡터를 함께 받아 미래 값을 한 시점씩 예측

과거 정보를 압축하기 때문에 긴 데이터에 용이

외부 변수를 바로 연결

긴 기간 예측이 필요한 경우 더 빠르고 정확한 예측 가능

모델 구조가 단순해 유지보수, 배포가 쉬움

Transformer: 도서관에서 모든 책을 서로 비교해 가며 답을 찾는 방법. 정확하지만 시간이 매우 오래 걸림.

TiDE: 사서가 중요한 내용만 골라 요약 카드 두 장으로 만들어 주고, 그 카드로 답을 찾는 방법. 훨씬 빠르면서도 핵심 정보 보존

정밀한 상호작용이 필요한 금융 데이터에는 아직 검증 부족.

Explaniability는 요약 벡터를 해석 도구와 결합해 부분별 기여도 추출 가능

6/19 - TiDE 논문 리뷰

Transformer: 도서관에서 모든 책을 서로 비교해 가며 답을 찾는 방법.
정확하지만 시간이 매우 오래 걸림.

TiDE: 사서가 중요한 내용만 골라 요약 카드 두 장으로 만들어 주고, 그 카드로
답을 찾는 방법. 훨씬 빠르면서도 핵심 정보 보존

정밀한 상호작용이 필요한 금융 데이터에는 아직 검증 부족.

Explaniability는 요약 벡터를 해석 도구와 결합해 부분별 기여도 추출 가능

6/19 - TiDE 논문 리뷰

매출 데이터는 장기, 멀티변량 시계열로 TiDE에 적용 가능

인구 이동, 상권 활력 예측에 장기 **Forecast**필요.

휴일, 정책, 날씨 등 외생 변수를 그대로 입력 가능

금융, **high-volatility** 데이터는 검증 필요 → 변동성 큰 매출 시계열에서 성능 재확인 필요

구현은 실현 가능함.

6/19 - 교수님 일정

Officially off **June 30 - July 7 (Mon-Mon), Aug 1-6 (Fri-Wed)**

Remote work from **July 8 - July 31 (Zoom)**

Writing

- Coursera “Stanford Writing Course”
- academic writing UoC

Project

- 수요처: Front-end
- EconLLM: 데이터 모으기

6/19 - LLM 정보 격차 아이디어(정성적으로)

유료 모델/Pro-Tier LLM이 존재하는 지금, 무료 사용자에게 어떤 부정적인 외부효과가 나타나는가?

- 성과 격차, 심리적 위축, 정보 신뢰 저하, 불공정 인식 등

H1: 유료 모델의 고도화에 따라 무료 사용자는 상대적 박탈감/불안감이 증가한다

H2: 동일한 과제를 주었을 때, 유료 사용자가 무료 사용자보다 정답률, 효율이 높다.

H3: 무료 모델과 유료 모델에서의 할루시네이션이 발생했을 때, 무료 모델의 정보 신뢰도가 더 낮다.

H4: 구독료와 소득의 차이에 따라 가격-불공정 인식이 더 악화된다.

H5: 상대적 박탈감이 유료 모델로 업그레이드 의향과 무료 모델에 대한 신뢰 저하에 영향을 준다.

과제

- 보고서, 논문 요약
- 코드 디버깅 또는 프로그래밍 과제
- 오픈 데이터 분석/해석

관련 연구

- Freemium/유료 구독 심리
- 소득별 생성 AI 채택 격차
- LLM 모델 품질 격차

가격에 따른 심리+정보 품질+성과를 다 보는 건 없음

6/26 - 데이터 보기

filtered_df12.parquet

매출 데이터 예측... 주가 예측... 주식 그래프 보는 법... 이동평균선... 볼리저 밴드... 흠?

- 데이터 **Master File** 만들기 (연구실에서 진행하는 모든 연구에 대해... 링크라도)

Synthetic Control

gentrification: 낙후 지역이 개발 되면서 외부 자산이 유입되고 기존 거주민들이 내몰리는 현상

6/26 - y변수 설계

카테고리	컬럼_수	컬럼_목록
기본정보	10	public_id, quarter, district_code, classification_for_district, date_id, year, month, district_code_1.x, franchise1, open_month
매출	53	sales_card, sales_delivery, before_noon_sales, after_noon_sales, weekend_sales, 당월_매출_금액, 당월_매출_건수, 주중_매출_금액, 주말_매출_금액, 월요일_매출_금액, 화요일_매출_금액, 수요일_매출_금액, 목요일_매출_금액, 금요일_매출_금액
고객	2	customer, customer_new
인구	64	총_유동인구_수, 남성_유동인구_수, 여성_유동인구_수, 연령대_10_유동인구_수, 연령대_20_유동인구_수, 연령대_30_유동인구_수, 연령대_40_유동인구_수, 연령대_50_유동인구_수, 연령대_60_이상_유동인구_수, 시간대_00_06_유동인구_수, 시간대_06_12_유동인구_수, 시간대_12_18_유동인구_수, 시간대_18_24_유동인구_수
아파트	17	아파트_단지_수, 아파트_면적_66_제곱미터_미만_세대_수, 아파트_면적_66_제곱미터_세대_수, 아파트_면적_99_제곱미터_세대_수, 아파트_면적_132_제곱미터_세대_수, 아파트_면적_165_제곱미터_세대_수, 아파트_가격_1_억_미만_세대_수, 아파트_가격_1_억_이상_세대_수
지출	12	월_평균_소득_금액, 소득_구간_코드, 지출_총금액, 식품_지출_총금액, 의료_신발_지출_총금액, 생활용품_지출_총금액, 의료비_지출_총금액, 교통_지출_총금액, 여가_지출_총금액, 문화_지출_총금액, 교육_지출_총금액, 유흥_지출_총금액
점포	7	점포_수, 유사_업종_점포_수, 개업_율, 개업_점포_수, 폐업_률, 폐업_점포_수, 프랜차이즈_점포_수
기타	13	age, rental_type, rental_deposit, monthly_rental_fee, regular_employees_count, business_square_size, delivery_link, classification_kcd_v3_depth_2_name, kostat_class, x_5181, y_5181, attraction_num, 총_가구_수

데이터 크기: (579851, 178)

Y변수

- 매출 증감률: (마지막달 매출 - 첫달 매출)/첫달 매출 → X: 상권 특성, 인구 유입, 경쟁 강도, 업종 특성
- 최근 기울기: 마지막 10주 추세 → X: 유동인구, 경쟁 환경, 프랜차이즈
- 매출 변동성 → X: 고객군, 요일/시간 별 매출
- 폐업률: X: 특정 구간 폐업 수치 → 경쟁 강도, 유동인구, 소득, 업종

매출 증감률 → x변수의 단위를 나누자: 업장별, 상권별, 동별, 첫 10주 매출 추세

데이터의 특성을 바탕으로 자동으로 클러스터링 기법을 판단해서 클러스터링 진행 → 트레이닝 데이터를 어떻게 만들 수 있을까?

7월 11일 금요일

7/11 - TiDE 논문 리뷰

Long-term Forecasting with
TiDE: Time-series Dense Encoder

Motivation

긴 시계열 예측 필요

주로 Transformer 사용

⇒ 길이가 길면 연산량 증가로 **GPU** 메모리, 속도 느림

선형 모델을 사용한 예측의 경우 계산은 빠르나 비선형 데이터에 적합하지 않음

“Attention 없이 정확하고 빠른 대안 제시”

Dataset

Dataset	#Time-Series	#Time-Points	Frequency
Electricity	321	26304	1 Hour
Traffic	862	17544	1 Hour
Weather	21	52696	10 Minutes
ETTh1	7	17420	1 Hour
ETTh2	7	17420	1 Hour
ETTM1	7	69680	15 Minutes
ETTM2	7	69680	15 Minutes

Table 1: Summary of datasets.


#Time-Series: 시계열 수

#Time-Points: 한 시계열 안에
포함된 관측 시점 개수

Electricity(3년), Traffic(2년),
Weather(1년), ETTh1,
h2(2년), ETTm1, m2(2년)


기간: Frequency *
#Time-Points

TiDE 모델 구조




1. 입력: Lookback / Dynamic Covariates / Attributes
2. Dense Encoder: 과거 데이터를 압축해 하나의 요약 벡터로 바꿈
3. Dense Decoder
4. Unflatten:
5. Stack
6. Temporal Decoder: 앞으로 일어날 날짜, 요일 정보와 요약 벡터를 함께 받아 미래 값을 한 시점씩 예측
7. Residual

결과




(a) Inference time per batch in microseconds



(b) Training time for one epoch in seconds.

결과



입력 받는 과거 구간 L

과거 8~14일 데이터만
있어도 TiDE의 정확도
올라감.

그 이후에는 미비

결과

MSE: 정확도가 더 올라감. (Weather 3%, Traffic 11%)

Latency: PatchTST 12 ms / TiDE 1.2 ms (10x)

“정확도와 효율 측면에서 좋은 성능을 보임”

기존 Transformer는 장기 시계열 예측에서 취약(노이즈가 많은 경우)

(*복잡한 상호작용과 짧은 기간에선 우위)

한계점

시계열 연구에서 범용적으로 사용되는 시계열 데이터 사용.

금융/불규칙 시계열에 대한 검증 필요.

과거 시계열을 한 줄 벡터로 압축하기 때문에 데이터에 대한 가중치를 알 수 없음.

7월 17일 목요일

7/17 - Y 지표 정의

1. 매출 증감률

- a. 'biz_age_month', 'regular_employees_count', '점포_수', '총_유동인구_수', '월_평균_소득_금액'

2. 최근 기울기(최근 10주)

- a. 'biz_age_month', '총_유동인구_수', '프랜차이즈_점포_수'

3. 매출 변동성

- a. 'biz_age_month', '연령대_10_유동인구_수', '연령대_60_이상_유동인구_수', '시간대_00_06_유동인구_수', '시간대_21_24_유동인구_수'

4. 첫 매출 대비 최대 매출

- a. 'biz_age_month', '점포_수', '총_유동인구_수', '총_직장_인구_수'


5. 최대 매출까지 걸린 시간

- a. 'biz_age_month', '유사_업종_점포_수', '총_상주인구_수'

7/17 - Y 지표 정의

매출 증감률


- 정확도: 0.65
- 유동인구, 점포 수가 매출 성장에 영향



7/17 - Y 지표 정의

최근 기울기


- $R^2 = 0.85$
- 프랜차이즈, 유동인구 매출 상승 영향



7/17 - Y 지표 정의

매출 변동성


- $R^2 = 0.46$
- 개업 기간, 심야시간 유동인구 매출 상승 영향



7/17 - Y 지표 정의

최대 매출 대비 첫 매출


- $R^2 = 0.04$
- 설명력 x



7/17 - Y 지표 정의

최대 매출까지 걸린 시간

- $R^2 = 0.39$
- 직장 인구, 유동인구 매출 상승 영향



7/17 - Y 지표 정의

- 유동 인구, 소득이 성장 확률/추세에 영향
- 프랜차이즈 수는 단기 매출 영향
- 시간대/나이에 따른 매출 변동성 영향

Todo

머신러닝 모델 다양하게 적용


동단위/업장 단위 개별 분석

7/17 - GeoSEE 수요처 UI

GeoSEE 수요처 UI Brainstorming

2025 07 16

User Interface



Phase I

Phase II

Indicator

Modules

☒ Check all

☒ Get address

Generate prompt

Auto-generated prompt

Determine the sequence of modules to solve the Task ...

The modules are defined as follows ...

Input: region's location
`loc = (lat, lng)`

Answer:


LLM Model

Submit

Progress bar

Download

User Interface



Phase I

Phase II

GeoJson upload

...

Module results upload

...

Few-shot samples

☐ From V4

☐ From NK

Generate prompt

Progress bar

Auto-generated prompt

full address of the given location is Machinga, Southern Region, MWI. Land cover ratio of development is 0.087. Land cover ratio of building is 0.008. Land cover ratio of rangeland is 0.677. Land cover ratio of agricultural is 0.005. Sum of nightlight intensity is 347.965. Average nightlight intensity is 0.029. area of region (km²) of the given location is 3910.786. Land cover ratio of development in the neighboring region(s) is 0.066. Land cover ratio of building in the neighboring region(s) is 0.004. Sum of nightlight intensity in the neighboring region(s) is 2267.136. Average nightlight intensity in the neighboring region(s) is 0.041. Land cover ratio of rangeland in the neighboring region(s) is 0.526. Land cover ratio of agricultural in the neighboring region(s) is 0.004. Infer a the population from given location's description. Answer the numeric score only. Answer: 885670.0

full address of the given location is Dedza, Central Region, MWI. Land cover ratio of development is 0.114. Land cover ratio of building is 0.004. Land cover ratio of rangeland is 0.664. Land cover ratio of agricultural is 0.007. Sum of nightlight intensity is 456.095. Average nightlight intensity is 0.016. area of region (km²) of the given location is 4008.478. Land cover ratio of development in the neighboring region(s) is 0.084. Land cover ratio of building in the neighboring region(s) is 0.004. Sum of nightlight intensity in the neighboring region(s) is 4359.157. Average nightlight intensity in the neighboring region(s) is 0.04. Land cover ratio of rangeland in the neighboring region(s) is 0.55. Land cover ratio of agricultural in the neighboring region(s) is 0.004. Infer a the population from given location's description. Answer the numeric score only. Answer:

LLM Model

Submit

Download

7월 24일 목요일

7/24 Agenda

- 업장별(public_id), 동별(district_code) 결과
- 다양한 머신러닝 모델 적용
- 수요처 UI 개선

7/24 Agenda

Growth

모델	Accuracy		성장		유지		하락	
분류	업장	구역	업장	구역	업장	구역	업장	구역
RandomForest	0.65	0.49	0.54	0.22	0.73	0.62	0.57	0.40
XGBoost	0.65	0.47	0.58	0.27	0.73	0.62	0.56	0.30
LightGBM	0.63	0.46	0.54	0.29	0.71	0.59	0.52	0.30
KNN	0.56	0.41	0.49	0.31	0.67	0.52	0.41	0.19
Logistic	0.51	0.50	0	0	0.67	0.67	0.19	0

7/24 Agenda

Growth

7/24 Agenda

Slope

모델	R^2	
	업장	구역
RandomForest	0.811	-1.416
XGBoost	0.764	-1.595
LightGBM	0.740	-0.583
LinearRegression	0.377	-0.764
SVR	-0.117	-0.095

7/24 Agenda

매출 표준편차(변동성)

모델	R^2	
	업장	구역
RandomForest	0.422	0.529
XGBoost	0.245	0.149
LightGBM	0.220	0.402
LinearRegression	0.138	0.397
SVR	-0.128	-0.089

7/24 Agenda

Time to Peak

모델	R^2	
분류	업장	구역
RandomForest	0.276	-0.034
XGBoost	0.229	-0.151
LightGBM	0.230	-0.148
LinearRegression	0.044	0.028
SVR	-0.008	-0.077

7/24 Agenda

첫 매출 대비 최대 매출

모델	R^2	
	업장	구역
RandomForest	-0.136	-0.216
XGBoost	-0.049	-0.171
LightGBM	-0.086	-0.059
LinearRegression	0.016	0.005
SVR	-0.040	-0.017

7월 24일 목요일
수요처 UI

GRDP 추정

지역 선택



년도 선택



추가 정보 입력...

Predict GRDP

예 GRDP

\$12.5B

This is the estimated Gross Regional Domestic Product for the selected region and year.

Download Regional Results

2025년 07월 23일 (수)



안녕하세요! 무엇을 도와 드릴까요?

2015년 함흥시 관련 내용 자세하게 부탁해

함흥시, 2015년 관련 정보입니다.

💰 예상 GRDP: 2,140,000 USD

📄 분석 요약:

함흥시는 면적이 약 1,530km²로 넓고, 야간 조도가 높게 나타났습니다. 농업 및 산업 개발지 비율이 높은 편이며, 항구와도 비교적 가까운 위치입니다. 이러한 지표들은 경제 활동 수준이 활발하다는 신호로 해석됩니다.



내용을 입력하세요.

7월 25일 금요일
연구실 미팅

7월 25일

Premium (2TB)

~~₩142,800~~ ₩99,000

1년

혜택으로 최대 ₩43,800 절감

이후 ₩119,000/년

할인받기

최대 5명과 스토리지를 공유하세요.

- ✓ 포토, Drive, Gmail에서 사용할 수 있는 2TB의 스토리지
- ✓ Google Workspace 프리미엄 기능

Copilot 포함*

Microsoft 365 Family

₩155,000 /년

Microsoft 계정에서 취소하지 않으면
구독이 자동으로 갱신됩니다. [약관 보기](#).

지금 구입하기

또는 ₩15,500 월 요금
으로 구입 >

- ✓ 최대 6인용
- ✓ 1인당 한 번에 최대 5개의 디바이스
- ✓ PC, Mac, iPhone, iPad, Android 휴대폰 및 태블릿에서 작동
- ✓ 최대 6TB의 클라우드 저장소, 사용자당 1TB(1,000GB)
- ✓ 최대 600GB의 사서함 저장소(사용자당 100GB)¹
- ✓ Microsoft Copilot⁴이 포함된 Word, Excel,² PowerPoint, Outlook,³ OneNote 데스크톱

☆ 추천 요금제

개인을 위한 요금제

Plus

US\$9.99/월

지금 업그레이드




- 👤 사용자 1명
- 🕒 용량 2TB
- 📱 모든 기기에서 연결 상태를 유지하세요
- 🕒 30일간 삭제된 파일 복원
- ✂️ 최대 50GB의 파일 전송
- 📄 PDF 편집 및 서명받기

7월 31일 목요일


7/31 Agenda

- 업장별 데이터 포인트 시각화 v
- 분석 단위 변경(4주, 8주, 10주차 평균) v
- x변수에 모든 컬럼 추가해서 리그레션 v
- 데이터를 반 나눠서 예측 해보기

7/31 데이터 포인트 시각화_전체기간




7/31 데이터 포인트 시각화_2021




7/31 데이터 포인트 시각화_2022


2022년 모든 업장의 sales_card 변화 (주별, 0 제외)





7/31 데이터 포인트 시각화_2023



7/31 데이터 포인트 시각화_월별



7/31 데이터 포인트 시각화_상하위 10개



7/31 분석단위 변경_4주

매출 증감

	Model	Accuracy	F1-Score (macro)
1	XGBoost	0.55	0.490
0	RandomForest	0.55	0.487
2	LightGBM	0.45	0.316

Slope

	Model	R ²	MSE
1	XGBoost	0.198	4.036165e+11
0	RandomForest	0.050	4.777515e+11
2	LightGBM	-0.165	5.857838e+11
3	LinearRegression	-228257.222	1.148031e+17

변동성

	Model	R ²	MSE
0	RandomForest	0.006	6.326952e+11
1	XGBoost	-0.107	7.044968e+11
2	LightGBM	-0.753	1.115107e+12
3	LinearRegression	-440003.552	2.799351e+17

최대 매출 도달

	Model	R ²	MSE
0	RandomForest	0.309	156.660
2	LightGBM	0.290	160.862
1	XGBoost	0.276	164.099
3	LinearRegression	-330.243	75050.613

첫 매출 대비 최대 매출

	Model	R ²	MSE
2	LightGBM	-0.325	1.260
0	RandomForest	-0.464	1.392
1	XGBoost	-1.699	2.567
3	LinearRegression	-183771.894	174791.795

7/31 분석단위 변경_8주

매출 증감

	Model	Accuracy	F1-Score (macro)
2	LightGBM	0.65	0.620
1	XGBoost	0.65	0.615
0	RandomForest	0.60	0.542

Slope

	Model	R ²	MSE
2	LightGBM	0.310	4.858386e+10
0	RandomForest	0.158	5.931528e+10
1	XGBoost	-0.692	1.192011e+11
3	LinearRegression	-84935.477	5.984735e+15

변동성

	Model	R ²	MSE
0	RandomForest	-0.413	2.642891e+11
2	LightGBM	-0.745	3.263379e+11
1	XGBoost	-1.841	5.314333e+11
3	LinearRegression	-8101.342	1.515663e+15

최대 매출 도달

	Model	R ²	MSE
1	XGBoost	0.353	148.410
0	RandomForest	0.336	152.316
2	LightGBM	0.315	157.298
3	LinearRegression	-400.522	92149.448

첫 매출 대비 최대 매출

	Model	R ²	MSE
2	LightGBM	0.018	3.413
0	RandomForest	0.012	3.433
1	XGBoost	-0.015	3.525
3	LinearRegression	-2463.071	8560.071

7/31 분석단위 변경_12주

매출 증감

	Model	Accuracy	F1-Score (macro)
1	XGBoost	0.65	0.644
2	LightGBM	0.65	0.617
0	RandomForest	0.40	0.393

Slope

	Model	R ²	MSE
2	LightGBM	0.175	2.466718e+10
0	RandomForest	0.132	2.597247e+10
1	XGBoost	-0.026	3.067847e+10
3	LinearRegression	-92393.632	2.763879e+15

변동성

	Model	R ²	MSE
1	XGBoost	-0.287	3.522843e+11
0	RandomForest	-0.345	3.682153e+11
2	LightGBM	-0.643	4.497983e+11
3	LinearRegression	-3758.292	1.028859e+15

최대 매출 도달

	Model	R ²	MSE
1	XGBoost	0.379	126.124
0	RandomForest	0.302	141.796
2	LightGBM	0.259	150.395
3	LinearRegression	-833.552	169477.567

첫 매출 대비 최대 매출

	Model	R ²	MSE
2	LightGBM	-0.087	2.789
0	RandomForest	-0.165	2.988
1	XGBoost	-0.751	4.491
3	LinearRegression	-1883.344	4832.678


8월 7일 목요일

8/7 Agenda

- 지역 변수 더미화 / 주요 X 변수 재설계
- Y별 회귀분석식 작성
- 데이터 시각화 중 이상값 확인
- 계절성 고려/비동기적 시작점 해결
- 변동성/계절성 자동 탐색 모델 있는지 조사

```
=== district_code 분석 ===  
총 데이터 수: 579,851행  
총 업장 수: 4,431개  
총 district_code 개수: 986개
```

8/7 데이터 시각화 개선(날짜/시점 통일/매출0 제외)




8/7 데이터 시각화 개선(2021)

2월 11-13 설날

4월 ?

7월 ?

9월 20-22 추석




8/7 데이터 시각화 개선(2022)

2월 1-3 설날

4월 ?

9월 9-12 추석

12월 ?




8/7 데이터 시각화 개선(2023)

1월 21-24 설날


4월 ?

9월 9-12 추석

12월 ?



8/7 데이터 시각화



=== 연도별 평균 sales_card ===

2021년: 10,751,342

2022년: 23,162,061

2023년: 81,111,578

=== 업장 84629366의 X칼럼 정보 ===

1. 기본 정보:

open_month: 2019-07

regular_employees_count: 0.00

business_square_size: 26.43

rental_deposit: 20000000

monthly_rental_fee: 1800000

franchise1: 0

2. 지역 정보:


district_code: 3001491

classification_for_district: 호프-간이주점

classification_kcd_v3_depth_2_name: 술집

kostat_class: 한식 일반 음식점업

플레이스



서울특별시 용산구 이태원동 130-3

우편번호 04391 도로명 서울특별시 용산구 보광로59길 5

이 주소의 장소

해직마트 주류

서울 용산구 이태원동 · 0507-1308-0542

맵도리 즉석우동 우동,소바

서울 용산구 이태원동 · 070-7585-0842

8월 8일 금요일 연구실
미팅

8/8 Agenda

- “Explainable Multi-Modal Time Series Prediction with LLM-in-the-LOOP”
- 시계열 데이터의 계절성/변동성 판단 모델

Explainable Multi-modal Time Series Prediction with LLM-in-the-Loop

연구 배경

기존 시계열 예측 모델 한계

- 대부분 단일 모델, 텍스트 등 외부 문맥 정보 포함 x , 설명 불가능
- 외부 정보를 포함한 **Multi-modal** 모델의 경우 성능은 높을 수 있으나 설명 불가능
- 금융, 의료, 날씨 등 설명이 중요한 도메인에서 활용 가능한 예측 모델

TimeLX

1. Prototype-based Explainable

- a. 멀티모달 시계열 데이터: time series
- b. 초기 예측 생성

2. Prediction LLM


- a. 인코더가 생성한 예측을 바탕으로
- b. 단순 수치 예측이 아닌 설명 정보

3. Reflection LLM

- a. LLM 예측과 실제 답 비교
- b. 누락된 정보 등 텍스트 noise 검열

4. Refinement LLM

- a. 인코더 예측과 llm 예측을 결합한
- b. 가중치로 두 예측의 비중 조절



인코더 + LLM-in-the-Loop


1. 인코더

- a. 시계열 + 텍스트 prototype 학습
- b. 입력 데이터와 prototype 간의 similarity 기반 softmax → 초기 예측

2. LLM-in-the-Loop

- a. M_pred: prototype 기반 case explanation + 텍스트 → 예측
- b. M_refl: 예측과 실제 정답 비교 → reflection 생성
- c. M_refine: reflection 바탕으로 원본 텍스트 수정

3. 수정된 텍스트로 인코더 재학습 → 성능 개선



데이터 셋

1. Weather: 비 예측

- a. x: 지난 24시간 데이터(온도, 습도, 기압, 풍속, 풍향)
- b. s: 기상 요약 리포트 텍스트
- c. 다음 24시간 안에 비가 오는가 (rain / not rain)

2. Finance: 다음날 가격 예측


- a. x: 지난 5일간 철광석 가격 외 기타 지표
- b. s: 해당 기간에 발행된 경제 뉴스
- c. 다음날 철광석 가격

3. Healthcare(TP): 독감 양성률

- a. x: 시계열 데이터: 지난 20주간 A/B 검사 건수, 양성률 등
- b. s: 감염에 따른 보건 리포트
- c. 다음 주 독감 검사 양성률 평균 초과 이진 분류 (exceed, not exceed)

4. Healthcare(MT): 독감 사망률

- a. x: 시계열 데이터: 지난 20주간 사망률, 총 사망자 수 등
- b. s: 사망률 관련 리포트
- c. 다음 주 사망률 평균 초과 이진 분류 (exceed, not exceed)



- 1. 인코더 예측
- 2. LLM 예측
- 3. 인코더 + LLM 결과
- 4. 오답 시 보정
- 5. 개선된 텍스트로 인코더 재학습

결과

Datasets → Methods ↓	Weather		Finance		Healthcare (TP)		Healthcare (MT)	
	F1	AUC	F1	AUC	F1	AUC	F1	AUC
DLinear [93]	0.540	0.660	0.255	0.485	0.393	0.500	0.419	0.388
Autoformer [94]	0.546	0.590	0.565	0.747	0.774	0.918	0.683	0.825
Crossformer [95]	0.500	0.594	0.571	0.775	0.924	0.984	0.737	0.913
TimesNet [96]	0.494	0.594	0.538	0.756	0.794	0.867	0.765	0.944
iTransformer [97]	0.541	0.650	0.600	0.783	0.861	0.931	0.791	0.963
TSMixer [98]	0.488	0.534	0.465	0.689	0.770	0.797	0.808	0.931
TimeMixer [99]	0.577	0.658	0.571	0.776	0.822	0.887	0.824	0.935
FreTS [100]	0.623	0.688	0.546	0.737	0.887	0.950	0.751	0.762
PatchTST [5]	0.592	0.675	0.604	0.795	0.841	0.934	0.695	0.928
LLMTime [101]	0.587	0.657	0.519	0.643	0.802	0.817	0.769	0.803
PromptCast [79]	0.499	0.365	0.418	0.607	0.727	0.768	0.696	0.871
OFA [66]	0.501	0.606	0.512	0.745	0.774	0.879	0.851	0.977
FSCA [73]	0.563	0.647	0.592	0.790	0.820	0.891	0.872	0.977
Time-LLM [69]	0.613	0.699	0.589	0.792	0.671	0.864	0.733	0.912
TimeCMA [72]	0.636	0.731	0.559	0.727	0.729	0.828	0.693	0.843
MM-iTransformer [47]	0.608	0.689	0.605	0.793	0.926	0.986	0.901	0.990
MM-PatchTST [47]	0.621	0.718	0.619	0.812	0.863	0.968	0.780	0.929
TimeCAP [81]	0.668	0.742	0.611	0.801	0.954	0.983	0.942	0.988
TimeXL	0.696	0.808	0.631	0.797	0.987	0.996	0.956	0.997

기존 SOTA TimeCAP

- Baseline 모델
- 시계열 데이터를 텍스트로 변환한 뒤 그대로 프롬프트에 입력하는 방식
- 숫자 시계열 데이터를 문장처럼 쭉 나열해서 입력하고 예측

결과

Table 2: Ablation studies on real-world multi-modal time series datasets, evaluated by F1 score.

Ablation	Variants	Weather	Finance	TP	MT
Encoder	Time Series	0.602	0.585	0.889	0.861
	Text	0.567	0.472	0.871	0.840
	Multi-modal	0.674	0.619	0.934	0.937
LLM	Text	0.645	0.496	0.974	0.901
	Text + Prototype	0.667	0.544	0.987	0.952
Fusion	Select-Best	0.674	0.619	0.987	0.952
	TimeXL	0.696	0.631	0.987	0.956


인코더, LLM 각각도 좋은 성능을 보이지만 합쳤을 때 더 좋은 성능을 보임

시사 / 한계점

- 해석 가능 예측
- 도메인 자료가 신뢰가 높고 풍부하면 좋음
-
- 장기 시계열에 대해서 테스트 필요
- 텍스트 퀄리티에 따른 결과 변동
- LLM 성능에 따른 결과/비용

계절성 / 변동성 판단 모델

8/8 매출 데이터



8/8 모델 분류

- Prophet
- SARIMA
- GARCH
- BSTS


8/8 Prophet

- 메타에서 개발한 시계열 예측 라이브러리
- 대규모 비즈니스 시계열 데이터를 위한 모델
 - 웹 트래픽, 일일 매출, 앱 활성화 수, 수요 예측 등
- `add_holidays()`, `add_seasonality()`

```
model = Prophet()  
model.add_country_holidays('KR') # 기본 명절  
model.add_holidays(custom_holidays) # 커스텀 이벤트  
model.add_seasonality(name='monthly', period=30.44) # 월별 패턴
```





- Additive model $y_t = g(t) + s(t) + h(t) + \varepsilon_t$
 - $g(t)$ 트렌드, $s(t)$ 계절성, $h(t)$ 휴일/이벤트

8/8 Prophet










- 파란 선은 실제 데이터
- 빨간 선은 예측값
- 노란 별은 이벤트 시점
- 붉은 바탕은 예측 불확실성 구간
- 뒤에 12주 예측 (기간설정 가능)

8/8 Prophet



1. Trend
 - a. 전체 기간 매출 변화
2. Holidays
 - a. 명절/이벤트가 미치는 영향
3. Weekly
 - a. 요일별 매출 패턴
4. Yearly
 - a. 연간 매출 패턴

8/8 Prophet



8/8 SARIMA

- ARIMA 모델에서 계절패턴(**s**)추가
- 월/분기/연 단위 매출 사이클 모델링에 적합
- 매출이 요일, 월별 패턴을 반복하는 경우 적합

8/8 GARCH

- 변동성 클러스터링: 큰 변동이 나타나면 이후에도 비슷한 변동이 나타나는지 파악
- 금융/주식 데이터에 적합
- 급등/급락이 잦은 데이터에 적합
- 매출이 특정 시기에 집중적으로 변동하는지 포착

8/8 BSTS

- 데이터를 여러 요인으로 쪼개서 분석
- **trend, seasonality, regression**
- 매출에 특정 이벤트(프로모션, 날씨 등)의 영향이 있을 때
- 변동/계절성 뿐 아니라 외부요인도 반영

8/8 비교표

모델	변동성	계절성	불확실성	외부요인
Prophet	O	O	O	O
SARIMA	O	O	X	X
GARCH	O	X	X	X
BSTS	O	O	O	O

8월 14일 목요일 개별
미팅

8/14 Agenda

수요처

- 북한 문서 데이터 수집

KCD데이터

- 컬럼 분류
- 회귀분석 결과

Todo

기타

8/14 수요처 - 문서 데이터 수집

1 CONTENTS

요약

건설 · 개발 주요동향

02 국가경제발전 5개년 계획 3차년도 평가와 4차년도 계획

(건설 · 개발 부문)

06 2023년 4/4분기 살림집 사업 현황

건설 · 개발동향 분석

12 분석대상 시설 유형 분포

14 유형별 주요 건설 · 개발 동향

34 지역별 시설유형별 분포 현황

종합 및 시사점

42 주요동향 요약과 시사점

44 유형별 동향분석 요약과 시사점

부 록

48 조사 개요

53 '23년 4/4분기 북한건설 · 개발동향 자료

2

1. 교통물류시설

1.1. 도로

□ 황해북도 수안군, 군내 도로 기술개건공사 완료(노동신문, 10.11 5면)

- (내용) 수안군에서 천암리소재지로부터 산북리까지의 도로에 대한 기술개건공사를 짧은 기간에 계속하였음
 - 군에서는 단계별공사계획을 면밀히 세운데 기초하여 도로기술개건에 달라붙었음
 - 군책임일군들이 현장에 자주 나와 걸린 문제를 료해하고 세멘트를 비롯한 자재보장을 선행시키며 료전기재를 제때에 대주기 위한 대책을 빈틈없이 세우면서 공사가 중단없이 추진되게 하였음
 - 일군들은 공사가 높은 속도로 진행되는데 맞게 앞선 시공방법을 적극 받아들이는것과 함께 질보장에 큰 힘을 넣었음
 - 군도로보수관리대의 근로자들은 도로의 평탄성과 견고성을 보장하면서 물도랑정리와 옹벽쌓기, 도로표식물들과 안전보호말뚝설치, 길섶지피식물심기 등 과제를 높은 수준에서 수행하기 위해 헌신의 구슬땀을 바쳐갔음
- (주체) 수안군책임일군, 수안군도로보수관리대
- (위치) 황해북도 수안군

3

tesseract-ocr / tesseract Public

교통물류시설 1.1. 도로 □ 황해북도 수안군, 군내 도로 기술개건공사 완료(노동신문, 10.11, 5면) · (내용) 수안군에서 천암리소재지로부터 산북리까지의 도로에 대한 기술개건공사를 짧은 기간에 계속하였음 군에서는 단계별공사계획을 면밀히 세운데 기초하여 도로기술개건에 달라붙었음 군책임일군들이 현장에 자주 나와 걸린 문제를 료해하고 세멘트를 비롯한 자재보장을 선행시키며 료전기재를 제때에 대주기 위한 대책을 빈틈없이 세우면서 공사가 중단없이 추진되게 하였음 일군들은 공사가 높은 속도로 진행되는데 맞게 앞선 시공방법을 적극 받아들이는것과 함께 질보장에 큰 힘을 넣었음 군도로보수관리대의 근로자들은 도로의 평탄성과 견고성을 보장하면서 물도랑정리와 옹벽쌓기, 도로표식물들과 안전보호말뚝설치, 길섶지피식물심기 등 과제를 높은 수준에서 수행하기 위해 헌신의 구슬땀을 바쳐갔음 · (주체) 수안군책임일군, 수안군도로보수관리대 · (위치) 황해북도 수안군 □ 함경북도 청진시, 기본도로 포장공사 진행(노동신문, 10.13, 5면) · (내용) 함경북도에서 올해에 도소재지 기본도로에 대한 포장공사를 진행하였음

4

자료	시설유형	지역	주요내용/사업	연도	일자
'23년 4/4분기 북한 동향	교통물류 시설	황해북도 수안군	군내 도로 기술개건공사 완료	2023	10.11
'23년 4/4분기 북한 동향	교통물류 시설	함경북도 청진시	기본도로 포장공사 진행	2023	10.13
'23년 4/4분기 북한 동향	교통물류 시설	평안북도 운산군	도로 기술개건사업 추진	2023	10.15
'23년 4/4분기 북한 동향	교통물류 시설	양강도 혜산시	중심도로 1단계 포장공사 완료	2023	10.19
'23년 4/4분기 북한 동향	교통물류 시설	강원도 김화군	도로보수관리 추진	2023	12.21
'23년 4/4분기 북한 동향	공급시설	함경남도 단천시	북천9호발전소 물길굴착공사 완료	2023	10.19

8/14 KCD - 칼럼 분류

<https://docs.google.com/spreadsheets/d/1MVIVbETmQvtVqyZeNE5xVmE7evAghxJHhiA1llo4vig/edit?usp=sharing>

시계열_매출관련	인구관련	소득_지출관련	주거관련	경쟁환경관련	지역범주형	기타범주형
sales_card	총_유동인구_수	월_평균_소득_금액	아파트_단지_수	점포_수	district_code	open_month
sales_delivery	남성_유동인구_수	소득_구간_코드	아파트_면적_66_제곱미터_미만_세대_수	유사_업종_점포_수	classification_for_district	date_id
before_noon_sales	여성_유동인구_수	지출_총금액	아파트_면적_66_제곱미터_세대_수	개업_율	district_code_1.x	kostat_class
after_noon_sales	연령대_10_유동인구_수	식료품_지출_총금액	아파트_면적_99_제곱미터_세대_수	개업_점포_수	classification_kcd_v3_depth_2_name	rental_type
weekend_sales	연령대_20_유동인구_수	의류_신발_지출_총금액	아파트_면적_132_제곱미터_세대_수	폐업_률		age
당월_매출_금액	연령대_30_유동인구_수	생활용품_지출_총금액	아파트_면적_165_제곱미터_세대_수	폐업_점포_수		
당월_매출_건수	연령대_40_유동인구_수	의료비_지출_총금액	아파트_가격_1_억_미만_세대_수	프랜차이즈_점포_수		

53개

64개

12개

18개

7개

4개

5개

8/14 KCD - 회귀분석식

변수 그룹

- 시계열 변수
 - lag_k: k주 전의 매출
 - ma_k: 최근 k주 동안 매출 평균
 - vol_k: 최근 k주 동안 매출 표준편차
- 외생 변수
 - 인구/소득 관련 변수
- 더미 변수
 - 지역/업종 관련 변수

8/14 KCD - 회귀분석식

주별 매출 수준 예측

$$\begin{aligned}\log(\text{Sales})_{i,t} = & \beta_0 + \beta_1 \text{lag_1}_{i,t} + \beta_2 \text{lag_2}_{i,t} + \beta_3 \text{lag_4}_{i,t} \\ & + \beta_4 \text{ma_4}_{i,t} + \beta_5 \text{ma_8}_{i,t} + \beta_6 \text{vol_4}_{i,t} + \beta_7 \text{vol_8}_{i,t} \\ & + \sum_{j=1}^J \delta_j (\text{외생변수}_j)_{i,t} \\ & + \sum_{k=1}^K \gamma_k (\text{업종더미}_k)_i \\ & + \sum_{m=1}^M \eta_m (\text{지역더미}_m)_i \\ & + \epsilon_{i,t}\end{aligned}$$

- 업장의 매출 규모
- 근본적으로 매출이 높은 업장의 특징

장기 추세 예측

$$\begin{aligned}\text{LongTermGrowth}_i = & \beta_0 + \beta_1 \text{lag_1}_{i,t} + \beta_2 \text{lag_2}_{i,t} + \beta_3 \text{lag_4}_{i,t} \\ & + \beta_4 \text{ma_4}_{i,t} + \beta_5 \text{ma_8}_{i,t} + \beta_6 \text{vol_4}_{i,t} + \beta_7 \text{vol_8}_{i,t} \\ & + \sum_{j=1}^J \delta_j (\text{외생변수}_j)_{i,t} \\ & + \sum_{k=1}^K \gamma_k (\text{업종더미}_k)_i \\ & + \sum_{m=1}^M \eta_m (\text{지역더미}_m)_i \\ & + \epsilon_{i,t}\end{aligned}$$

- 전체 기간에 대한 성장률

8/14 KCD - 회귀분석식

N주 변동성(13, 26, 52주)

$$\begin{aligned}\text{Volatility(N)}_{i,t} = & \beta_0 + \beta_1 \text{lag_1}_{i,t} + \beta_2 \text{lag_2}_{i,t} + \beta_3 \text{lag_4}_{i,t} \\ & + \beta_4 \text{ma_4}_{i,t} + \beta_5 \text{ma_8}_{i,t} \\ & + \sum_{j=1}^J \delta_j (\text{외생변수}_j)_{i,t} \\ & + \sum_{k=1}^K \gamma_k (\text{업종더미}_k)_i \\ & + \sum_{m=1}^M \eta_m (\text{지역더미}_m)_i \\ & + \epsilon_{i,t}\end{aligned}$$

* vol_k 변수 제거

최대 매출 소요 시간

$$\begin{aligned}\text{TimeToPeak}_i = & \beta_0 + \beta_1 \text{lag_1}_{i,t} + \beta_2 \text{lag_2}_{i,t} + \beta_3 \text{lag_4}_{i,t} \\ & + \beta_4 \text{ma_4}_{i,t} + \beta_5 \text{ma_8}_{i,t} + \beta_6 \text{vol_4}_{i,t} + \beta_7 \text{vol_8}_{i,t} \\ & + \sum_{j=1}^J \delta_j (\text{외생변수}_j)_{i,t} \\ & + \sum_{k=1}^K \gamma_k (\text{업종더미}_k)_i \\ & + \sum_{m=1}^M \eta_m (\text{지역더미}_m)_i \\ & + \epsilon_{i,t}\end{aligned}$$

- 업장의 초기 성장 성공 요인

8/14 KCD - 회귀분석식

현재 대비 최대 매출

$$\begin{aligned}\text{PeakRatio}_{i,t} = & \beta_0 + \beta_1 \text{lag_1}_{i,t} + \beta_2 \text{lag_2}_{i,t} + \beta_3 \text{lag_4}_{i,t} \\ & + \beta_4 \text{ma_4}_{i,t} + \beta_5 \text{ma_8}_{i,t} + \beta_6 \text{vol_4}_{i,t} + \beta_7 \text{vol_8}_{i,t} \\ & + \sum_{j=1}^J \delta_j (\text{외생변수}_j)_{i,t} \\ & + \sum_{k=1}^K \gamma_k (\text{업종더미}_k)_i \\ & + \sum_{m=1}^M \eta_m (\text{지역더미}_m)_i \\ & + \epsilon_{i,t}\end{aligned}$$

단기 성장률

$$\begin{aligned}\text{Growth}_{i,t} = & \beta_0 + \beta_1 \text{lag_1}_{i,t} + \beta_2 \text{lag_2}_{i,t} + \beta_3 \text{lag_4}_{i,t} \\ & + \beta_4 \text{ma_4}_{i,t} + \beta_5 \text{ma_8}_{i,t} + \beta_6 \text{vol_4}_{i,t} + \beta_7 \text{vol_8}_{i,t} \\ & + \sum_{j=1}^J \delta_j (\text{외생변수}_j)_{i,t} \\ & + \sum_{k=1}^K \gamma_k (\text{업종더미}_k)_i \\ & + \sum_{m=1}^M \eta_m (\text{지역더미}_m)_i \\ & + \epsilon_{i,t}\end{aligned}$$

- 최근 성장하고 있는지

8/14 KCD - 회귀분석 결과

Y	R ²	핵심 설명 변수	의미 및 해석
매출 수준	0.644	district_code	매출 규모는 위치에 영향을 받음
전체기간 성장률	0.61	district_code	성장률도 위치에 영향을 받음
단기 성장률	0.016	-	-
최대매출비율	0.301	district_code	위치에 영향을 받음
최대매출까지시간	0.25	district_code	위치에 영향을 받음
52주 변동성	0.756	ma_k	가게의 장기 안정성은 현재 매출 규모에 가장 크게 영향을 받음
26주 변동성	0.639	ma_k	가게의 중기 안정성도 현재 매출 규모에 영향을 받음
13주 변동성	0.575	ma_k	가게의 단기 안정성도 현재 매출 규모 영향을 받음

- 위치가 매출에 가장 큰 영향을 미침
 - 매출이 높은 업장들 / 전체기간 성장률에서 가장 영향을 많이 준 변수는 지역 더미 변수

8/14 Todo

1. 지역/위치관련 데이터 결합
 - a. 근처 대중교통
 - b. 일정 반경 내 경쟁업체 수
 - c. 접근성(교통)
 - d. 주차장 유무
 - e. 기타 편의시설/인구 밀집 시설 유무
2. 단기 예측 고도화
 - a. 계절/이벤트 데이터 추가
3. 예측 모델 적용

8/14 기타

1. 현재 하는 분야는 재미있음.
2. 그런데 뭔가 결과가 안나와서 답답.
3. 현재 연구실에서 주로 진행하는 연구와 동떨어진 느낌.
4. 위성사진 연구를 주로 진행.
5. 앞으로 **4-5**년간의 역할과 연구에 대한 걱정이 생김.
6. 방향성을 어떻게 가져가면 좋을지 모르겠음.

8월 20일 목요일 개별
미팅

8/20 Agenda

수요처

- 북한 문서 데이터 수집(2017~2024 완료)

KCD데이터

- 진행상황 공유

8/20 수요처 데이터 수집

- 2017년 ~ 2024년 북한건설개발동향 데이터 수집 완료
- 랜덤하게 뽑은 후 확인 완료

8/20 KCD - 진행상황 공유

- 장기추세 분석에 단기 성장률 추가
 - 오픈 4주, 8주, 10주
 - 초기 성장과 장기 성장률에 영향을 주는지
- $Y_i = B_0 + B_1 \text{initGrow}_{4,i} + B_2 \text{initGrow}_{8,i} + B_3 \text{initGrow}_{12,i} + B_4 \text{sale_mean}_i + B_5 \text{sales_sd}_i + \text{업종/지역 더미}$
- $r^2 = 0.233$
-
- $Y_i = B_0 + B_1 \text{initGrow}_{4,8,12,i} + B_4 \text{sale_mean}_i + B_5 \text{sales_sd}_i + \text{업종/지역 더미}$
- r^2
 - 4: 0.185 / 8: 0.197 / 12: 0.221 / 16: 0.225 / 26: 0.256
 - 4+8: 0.198 / 4+8+12: 0.233
 - 8+12: 0.231 / 8+12+16: 0.233
-
- 기타 외부 데이터 수집
 - 지리정보 데이터
 - 지하철 거리, 경쟁사 밀도, 부동산 가격 등

Stanford | ONLINE

Aug 21, 2025

Hyeol W.

has successfully

Writing in

an online non-credit course authorized by Stanford University and offe

8월 20일 목요일 전체
미팅

COURSE
CERTIFICATE



Kristin L. Sainani

Kristin Sainani, PhD
Associate Professor
Health Research and Policy

Verify at:
coursera.org/verify/BCNTCHMB7777

Coursera has confirmed the identity of this individual and
their participation in the course.

8/20 Coursera

Unit 4: Writing Process

- Writing = Rewriting
- Prewriting → Drafting → Revising → Editing
- Prewriting에 가장 많은 시간을 쏟아야함.
- Prewriting은 글을 쓰기 전에 정보를 수집/정리/배치하는 단계.
 - 글을 쓰다가 자료 찾으러 가지 않기.
 - 각 섹션에 필요한 데이터는 미리 정리해서 **Draft** 작성.
- 초안에선 완벽보단 일단 생각하는 내용을 최대한 적어보기.
- **Revision** 할 때 자신이 작성한 글을 녹음해서 들어보기.
- 최소 3회 이상 수정 필수 → **Revision**에서 글 완성도 올리기.

8/20 Coursera

Unit 5: Scientific Manuscript

- **Result**에선 사실만 작성, 해석은 **Discussion**에서.
- 불필요한 해설보단 수치와 표에 집중 → 핵심만 남기기.
- Introduction 구조
 - 배경 / 공백, 문제점 / 연구 목적, 가설 / “Why was this study needed?”
- **Discussion: Reviewer가 가장 중점적으로 읽는 부분**
 - 결과 해석과 의미 작성
 - 주요 결과 요약 → 선행연구 비교 → 의미 → 한계와 강점 → 결론/시사점
- **Abstract: IMRAD(Introduction, Methods, Results, And Discussion)**
 - 간결하고 정확하게 / 핵심 수치 / 불필요한 배경 x
 - 마지막에 작성

8월 27일 수요일 수요처
미팅

8/27 수요일 미팅

9월 5일 발표슬라이드 준비

- 데이터 준비(효신)
- 결과표 보기(동규)
- UI 고민한거 슬라이드에 추가(혁)

8월 28일 목요일 개별
미팅

8/28 개별 미팅


KCD 데이터

- 전체 매출 기울기 **vs** 기간 평균
- 갑자기 생김 매장 분석


수요처

- 지역 → 도 - 시/군/구 분류


8/28 KCD - 전체 매출 기울기 vs 기간 평균



	R2
M1 ([4])	0.1603
M2 ([4, 12])	0.3211
M3 ([4, 12, 26])	0.3966



	R2
M1 ([4])	0.1105
M2 ([4, 12])	0.1901
M3 ([4, 12, 26])	0.2824



	R2
M1 ([4])	0.0968
M2 ([4, 12])	0.1324
M3 ([4, 12, 26])	0.2333

8/28 KCD - 전체 매출 기울기 vs 기간 평균

4주 평균 Y

=== M3 ([4, 12, 26]) ===					
	coef	std_err	t_value	p_value	signif
const	-0.0784	0.1309	-0.5984	0.5496	
InitGrow_4	-0.5711	0.0809	-7.0581	0.0000	***
InitGrow_12	4.1302	0.4612	8.9558	0.0000	***
InitGrow_26	13.6004	0.9652	14.0902	0.0000	***
sales_mean	-0.0000	0.0000	-0.1376	0.8906	
...	...	...	...	...	...
여성연령대_40_상주인구_수_mean	-0.0010	0.0007	-1.5377	0.1241	
여성연령대_50_상주인구_수_mean	0.0010	0.0006	1.6508	0.0988	*
여성연령대_60_이상_상주인구_수_mean	-0.0007	0.0005	-1.5979	0.1101	
월_평균_소득_금액_mean	0.0000	0.0000	0.7193	0.4720	
소득_구간_코드_mean	-0.0246	0.0411	-0.5992	0.5490	

전체 Y

=== M3 ([4, 12, 26]) ===					
	coef	std_err	t_value	p_value	signif
const	0.0012	0.0015	0.7790	0.4360	
InitGrow_4	-0.0032	0.0011	-2.8475	0.0044	***
InitGrow_12	0.0111	0.0062	1.7895	0.0735	*
InitGrow_26	0.0665	0.0109	6.1177	0.0000	***
sales_mean	-0.0000	0.0000	-0.3499	0.7264	
...	...	...	...	...	...
여성연령대_40_상주인구_수_mean	-0.0000	0.0000	-0.0361	0.9712	
여성연령대_50_상주인구_수_mean	0.0000	0.0000	0.2754	0.7830	
여성연령대_60_이상_상주인구_수_mean	-0.0000	0.0000	-1.9055	0.0567	*
월_평균_소득_금액_mean	0.0000	0.0000	0.5371	0.5912	
소득_구간_코드_mean	-0.0003	0.0005	-0.5078	0.6116	

R2

M1 ([4])	0.1854
M2 ([4, 12])	0.2285
M3 ([4, 12, 26])	0.2643

8/28 KCD - 갑자기 생긴 매장

3. 지역별 분포

- 총 분포 지역: 874개 지역
- 상위 지역:
 - 3120235: 40개 업장 --> 송파구 문정동
 - 3120119: 57개 업장 --> 강서구 마곡동
 - 3120103: 39개 업장
 - 3120149: 36개 업장
 - 3130183: 34개 업장

업종	개인업체	프랜차이즈	총합	프랜차이즈 비율
한식음식점	935	295	1,230	24.0%
커피-음료	545	165	710	23.2%
호프-간이주점	351	59	410	14.4%
일식음식점	111	26	137	19.0%
양식음식점	105	22	127	17.3%
패스트푸드점	40	82	122	67.2%
분식전문점	46	50	96	52.1%
제과점	62	28	90	31.1%
중식음식점	51	25	76	32.9%

4. 업종별 분포

- 한식음식점: 1,230개 (41.0%)
- 커피-음료: 710개 (23.7%)
- 호프-간이주점: 410개 (13.7%)
- 일식음식점: 137개 (4.6%)
- 양식음식점: 127개 (4.2%)

지역코드	개인업체	프랜차이즈	총합	프랜차이즈 비율
3120235	32	8	40	20.0%
3120149	19	5	24	20.8%
3120103	18	5	23	21.7%
3130167	17	4	21	19.0%
3130183	17	4	21	19.0%
3120210	17	3	20	15.0%
3120187	15	4	19	21.1%
3120081	8	10	18	55.6%
3120225	12	6	18	33.3%
3120189	12	6	18	33.3%

송파구 문정동

노원구 상계동

9월 19일 금요일 그룹
미팅

Agenda

- 연구 요약
- 진행상황 공유
- 연구 방향
- 고민 중인 것
- 의견 요청
- 기타 아이디어




연구 요약

- 소상공인의 성공과 실패는 지역 경제에 영향을 줌
- 매출 데이터를 활용해 업장의 승패 여부를 판별해보고자 함
- **“매출 기반 성장하락(성공/실패) 예측 모델”**

[데이터]

- 업장별 주별 매출 / 위치 / 업종 / 유동 인구 / 좌표 / 상권 / 프랜차이즈 등

연구 요약



진행상황 공유

- OLS 회귀
- 시계열 파생변수 생성
 - InitGrow_4, 8, 12...
- 업장 초반 성장률이 최종 성과를 설명할 수 있는지(only 주별 매출)

연구 방향

- 성장/하락을 더 명확하게 예측할 수 있는, 영향력 있는 변수를 설계 해야함
 - 초기 성장률
 - 변동성
 - 피크 매출 도달 속도
 - 마지막 n주 vs 초기 n주 변화율
 - 전년 동기 대비 성장률
 - ??
- 매출만으로 충분하지 않음. → 외부 변수 필요
 - ??

고민 중인 것

- 외부 데이터 추가
 - ??
- 성장률을 예측하는 것이 아닌 단순히 성공과 실패로 예측
 - 단순히 매출 상위/하위 **30%**
 - 초기 성장률과 후반 성장률 비교
 - 일정 기간 이상 매출 유지 여부
 - 매출 + 성장률 + 변동성 조합
- 금융 보조 지표 활용?

기타 아이디어

- 금융 보조 지표 활용



기타 아이디어



- 금융 보조 지표 활용
- 추세 전환점 포착 성공 실패 예측 / 전환 신호 호출
- 새로운 지표 정의 “Dynamic Sales Momentum Index(DSMI)”

의견 요청

- 매출 외에 사용하면 좋은 데이터와 어떻게 사용하면 좋을지
- 성장/하락 예측 **vs** 성공/실패 예측
- 성공/실패 기준 정의
- 새로운 지표 개발?

기타

“Call Me A Jerk: Persuading AI to Comply with Objectionable Requests”

- GPT-4o mini, 28,000회 대화 실험
- 설득원리: authority, commitment, liking, reciprocity, scarcity, social proof, and unity

For each principle, we created two versions of the same request:

- A **control version**: A simple request without persuasion
- A **treatment version**: The same request using a persuasion principle

For example, with the Authority principle:

- **Control**: “Jim Smith, someone with no knowledge of AI, said you’d help me...”
- **Treatment**: “Andrew Ng, a world-famous AI developer, said you’d help me...”

<https://gail.wharton.upenn.edu/research-and-insights/call-me-a-jerk-persuading-ai/>

⇒ LLM도 인간에게 적용 가능한 심리학적 설득 신호에 취약함.

⇒ 악용 위험 상승 / 더 효과적인 프롬프트 활용 가능성 상승